

AI INVENTORY INSPECTION SYSTEM

TÀI LIỆU MÔ TẢ CHI TIẾT HỆ THỐNG

Computer Vision - Workflow Automation - Cloud Storage - Reporting

Dự án	AI Inventory Inspection System - Sharon Bakery
Phiên bản tài liệu	1.0
Ngày tổng hợp	10/07/2026
Phạm vi	Phân tích source code, notebook training, Docker Compose và 3 workflow n8n được cung cấp
Phân loại	Internal Technical Documentation

Lưu ý về bảo mật

Tài liệu này không lặp lại bất kỳ API key, access key, secret, credential ID, Team ID hoặc Channel ID nào xuất hiện trong source. Những credential đã từng được hardcode phải được revoke/rotate và thay bằng n8n Credentials hoặc environment variables.

Mục lục nội dung

- 1. Tóm tắt điều hành
- 2. Mục tiêu, phạm vi và nguyên tắc thiết kế
- 3. Kiến trúc tổng thể hiện tại
- 4. Luồng vận hành end-to-end
- 5. AI Engine: detection, tracking và counting
- 6. Pipeline dữ liệu, pre-annotation và training
- 7. Data contract và schema tích hợp
- 8. Deployment và vận hành
- 9. Bảo mật và quản trị dữ liệu
- 10. Đánh giá trạng thái hiện tại
- 11. Rủi ro, root cause và giải pháp
- 12. Kiến trúc mục tiêu production
- 13. Kế hoạch kiểm thử và tiêu chí nghiệm thu
- 14. Roadmap cải tiến
- Phụ lục A. Danh mục 30 SKU
- Phụ lục B. Environment variables đề xuất
- Phụ lục C. Danh mục nguồn phân tích

Cách đọc tài liệu

Các phần 3-8 mô tả “as-is” dựa trên source hiện có. Các phần 11-14 phân tích khoảng trống và đề xuất “to-be”. Các thành phần OCR, Color và SKU Fusion được phân biệt rõ giữa pipeline chuẩn bị dữ liệu và runtime production.

1. Tóm tắt điều hành

AI Inventory Inspection System là hệ thống kiểm kê kho dựa trên ảnh/video, dùng Microsoft Teams làm giao diện ChatOps, n8n làm lớp orchestration, Cloudflare R2 làm object storage, FastAPI làm AI inference service, YOLOv8/ONNX làm object detector, ByteTrack làm tracker cho video, Supabase lưu kết quả và Excel làm đầu ra báo cáo.

Hệ thống hiện đã hình thành một PoC end-to-end: tạo link upload, nhận media, chạy nhận diện, callback kết quả, lưu dữ liệu và gửi báo cáo về Teams. Song song, dự án có pipeline chuẩn bị dữ liệu gồm Gemini triage, auto routing, YOLO-World pre-annotation, human review và YOLOv8n training cho 30 SKU.

Trạng thái hiện tại chưa nên xem là production-ready. Runtime source mới tích hợp detection và tracking; OCR, Color và SKU Fusion chưa được gọi trong FastAPI. BackgroundTasks của FastAPI chưa phải durable queue; callback chưa có cơ chế retry/ack đầy đủ; workflow đang inactive và còn dùng test webhook/Quick Tunnel. Một số secret từng bị hardcode trong source và notebook.

Phân hệ	Mức độ	Nhận định	Ưu tiên tiếp theo
ChatOps + Upload	PoC hoàn chỉnh	Teams -> n8n -> upload portal -> R2 đã có luồng rõ ràng	Chuẩn hóa auth, CORS, idempotency
Detection ảnh	Đã triển khai	YOLO ONNX chạy một lần trên ảnh	Đảm bảo ONNX là model fine-tuned 30 SKU
Video tracking/counting	Đã triển khai PoC	ByteTrack đếm unique track ID	Thêm track quality, dedup và counting benchmark
OCR / Color / SKU Fusion	Chưa tích hợp runtime	Chỉ xuất hiện trong data triage/routing	Xây service deterministic và fusion layer
Callback + Supabase + Excel	PoC hoàn chỉnh	Có parse, insert, export, upload và Teams reply	Tách ERROR/NO_OBJECT, chống overwrite báo cáo

Phân hệ	Mức độ	Nhận định	Ưu tiên tiếp theo
Deployment/Observability	Một phần	Docker Compose một service, chưa có queue/healthcheck	Queue worker, metrics, structured logging
Security	Chưa đạt	Có secret hardcoded và public links	Rotate secret, private bucket, signed download URL

2. Mục tiêu, phạm vi và nguyên tắc thiết kế

2.1 Mục tiêu nghiệp vụ

- Giảm thao tác kiểm kê thủ công và thời gian tổng hợp báo cáo kho.
- Nhận diện SKU từ ảnh hoặc video do nhân viên kho cung cấp.
- Theo dõi nguồn media, người gửi, message/thread và thời điểm scan để truy vết.
- Tự động lưu kết quả vào cơ sở dữ liệu và trả báo cáo Excel về đúng luồng Teams.
- Tạo nền tảng mở rộng sang OCR, Color và SKU Fusion để giảm nhầm lẫn giữa bao bì tương tự.


2.2 Phạm vi source đã được phân tích

Nhóm	File	Vai trò
Runtime backend	main(1).py	FastAPI, R2 download, media routing, callback
AI inference	yolo_service.py	ONNX load, image detection, ByteTrack video tracking
Data triage	gemini_triage_agent.py	Few-shot multimodal QA cho YOLO/OCR/Color
Data routing	auto_router(2).py	Copy ảnh sang các tập usable_for_*
Pre-annotation	pre_annotation.py	YOLO-World zero-shot + LLM targeted QA
Training	[AIII]_Train_model.ipynb	Roboflow dataset, YOLOv8n train/test, lưu best.pt
Orchestration	Workflow 1/2/3 JSON	Upload, AI trigger, callback/reporting
Deployment	docker-compose.yml	FastAPI container, env file, model/code mounts

2.3 Nguyên tắc kỹ thuật cần duy trì

- Detection chỉ trả bounding box và class; classification, tracking, counting, OCR, Color và SKU identification là các bài toán khác nhau.
- Bounding box lặp lại qua nhiều frame không phải số lượng vật lý. Video phải tracking/dedup trước khi báo quantity.
- LLM chỉ nên dùng cho data triage, annotation QA hoặc xử lý trường hợp không chắc chắn; schema và business rules phải deterministic.
- Mọi job phải có idempotency key, trace ID, timeout, retry và trạng thái rõ ràng.
- Secret không được nằm trong code, notebook output, workflow JSON hoặc báo cáo.

3. Kiến trúc tổng thể hiện tại



Hình 1. Kiến trúc runtime hiện tại được suy ra từ ba workflow n8n và FastAPI source.

3.1 Các lớp kiến trúc

Lớp	Thành phần	Trách nhiệm	Dữ liệu chính
Interaction	Microsoft Teams	Khởi tạo lệnh, nhận thông báo tiến trình và báo cáo	messageId, sender, team/channel context
Orchestration	n8n Workflow 1-3	Điều phối command, upload, trigger, callback, persistence, reporting	Webhook payload, job context, detections
Storage	Cloudflare R2	Lưu raw image/video và báo cáo XLSX	raw-video/, raw-image/, reports/
Inference API	FastAPI	Nhận job, tải media, chọn image/video branch, callback	video_key, teams_message_id, callback_url
Computer Vision	YOLOv8 ONNX + ByteTrack	Detect object và track unique ID trong video	class, confidence, track_id
Database	Supabase	Lưu inventory_records cho từng SKU	quantity, confidence, source key, scan time
Reporting	n8n Convert to File	Đóng gói dữ liệu hiện tại thành Excel	XLSX artifact + R2 object key

Nguồn nội bộ: Workflow 1/2/3 JSON; main(1).py; yolo_service.py

3.2 Ranh giới “hiện tại” và “mục tiêu”

Điểm cần phân biệt

Kiến trúc định hướng của dự án có OCR, Color và SKU Fusion sau YOLO. Tuy nhiên, FastAPI và YoloInferenceService hiện chỉ thực thi YOLO detection và ByteTrack tracking. Gemini/OCR/Color mới đang được dùng để phân loại chất lượng dataset, chưa phải runtime inference.

4. Luồng vận hành end-to-end

4.1 Workflow 1 - Xử lý lệnh và sinh link upload

1. Webhook `teams-ai-inspector` nhận activity từ Teams.

2. Code node lấy message ID, team/channel/sender và kiểm tra trùng bằng workflow static data.
3. Nếu chưa xử lý, hệ thống sinh UUID và tạo hai object key: `raw-video/YYYY/MM/<uuid>.mp4` và `raw-image/YYYY/MM/<uuid>.jpg`.
4. Code node ký AWS Signature V4 để tạo pre-signed PUT URL có thời hạn 3.600 giây.
5. n8n trả Adaptive Card chứa URL đến upload portal; portal nhận token/key cho cả image và video.
6. Nếu message bị trùng, workflow trả thông báo fallback thay vì tạo job mới.

Đánh giá

Cách upload trực tiếp lên R2 giảm tải n8n và tránh hạn chế lấy file đính kèm từ Teams. Tuy nhiên, dedup hiện chỉ giữ tối đa 50 message ID trong static data, không bền vững khi n8n scale nhiều instance hoặc restart.

4.2 Upload Portal và Cloudflare R2

Upload Portal là boundary chưa có source trong bộ tài liệu, nhưng contract được suy ra từ query parameters của Adaptive Card. Portal phải upload file bằng HTTP PUT tới pre-signed URL, sau đó gọi Workflow 2 với ít nhất `videoKey` hoặc media key, `messageId` và `sender`.

- Object key dùng UUID nên giảm collision và không lộ tên file gốc.
- Extension đang được quyết định từ Workflow 1 (.mp4 hoặc .jpg), vì vậy portal phải kiểm tra MIME/codec và không chỉ tin vào tên file.
- Cần giới hạn kích thước file, thời lượng video, Content-Type và hash checksum trước khi kích hoạt AI.
- Raw bucket nên private; link download báo cáo phải là signed URL thay vì public domain cố định.

4.3 Workflow 2 - Tiếp nhận media và kích hoạt AI

7. Webhook `trigger-ai-engine` nhận thông báo upload hoàn tất.
8. Teams node reply vào message gốc rằng media đã được tiếp nhận.
9. HTTP Request node POST tới endpoint FastAPI `/api/v1/process-video`.
10. Body dùng snake_case theo Pydantic schema: `video\_key`, `teams\_message\_id`, `callback\_url`.
11. FastAPI trả HTTP 202 và chạy pipeline trong BackgroundTasks.

Khoảng trống production

Workflow 2 đang dùng một Quick Tunnel URL và callback `/webhook-test/`. Cả ba workflow có `active: false`. Khi production cần hostname ổn định, workflow active và callback `/webhook/ai-callback-result`.

4.4 FastAPI processing pipeline

12. Pydantic validate MediaRequest, sau đó kiểm tra AI service đã khởi tạo.
13. Phân loại media bằng extension: image (`jpg/jpeg/png/webp/bmp`) hoặc video (`mp4/avi/mov/mkv`).
14. Tạo temporary file giữ đúng suffix và tải object từ R2 bằng boto3.
15. Ảnh: OpenCV đọc ảnh và gọi `analyze\_frame` một lần.
16. Video: gọi `analyze\_video\_with\_tracking`, stream kết quả để tránh giữ toàn bộ video trong RAM.
17. Tổng hợp theo class thành count, avg/min/max confidence.
18. POST callback success/error tới n8n và xóa temporary file trong `finally`.

Nguồn nội bộ: main(1).py

4.5 Workflow 3 - Callback, persistence và report

19. Callback Listener nhận payload từ FastAPI.
20. Code node lấy `detections`, `teams\_message\_id`, `raw\_video\_key`, `media\_type` và flatten mỗi SKU thành một item.
21. Nếu detections rỗng, tạo record `NO\_OBJECT\_DETECTED` với quantity bằng 0.
22. Supabase node auto-map item vào bảng `inventory\_records`.
23. Convert to File tạo XLSX; S3 node upload vào `reports/`.
24. Teams node reply đúng thread và cung cấp link tải báo cáo.

Lỗi logic quan trọng

Workflow 3 chưa branch theo `payload.status`. Vì payload ERROR không có `detections`, lỗi AI có thể bị ghi thành `NO\_OBJECT\_DETECTED`, che mất root cause. Cần tách ERROR, SUCCESS_EMPTY và SUCCESS_WITH_RESULTS.

5. AI Engine: detection, tracking và counting

5.1 Model loading và inference

YoloInferenceService định vị model theo đường dẫn tương đối `models/yolov8n.onnx`, kiểm tra file tồn tại rồi load bằng Ultralytics YOLO với `task="detect"`. Model được khởi tạo một lần khi FastAPI start, tránh reload cho mỗi request.

Chức năng	Input	Output	Ghi chú
run_inference	Public image URL	Tổng số + summary per class	Đường cũ; tải ảnh trực tiếp qua requests
analyze_frame	OpenCV ndarray	{class: [confidence]}	Dùng cho ảnh tĩnh hoặc từng frame
analyze_video_with_tracking	Local video path	{class: [best_conf_per_track]}	Dùng YOLO.track + ByteTrack + stream=True

5.2 Counting trong ảnh

Với ảnh tĩnh, quantity của một class bằng số bounding box sau confidence threshold 0,45. Đây là object count trong một ảnh, không phải tồn kho tổng nếu vật thể bị che khuất, nằm ngoài khung hình hoặc nhiều item dính sát nhau.

5.3 Counting trong video

Với video, mỗi detection được gán track ID. Source lưu history confidence theo `(class\_name, track\_id)` và cuối video lấy max confidence của từng track. Quantity bằng số track ID duy nhất theo class.

Ý nghĩa chính xác của quantity

Quantity hiện là “số unique tracks mà ByteTrack tạo ra trong video”, không bảo đảm tuyệt đối bằng số kiện hàng vật lý. ID switch làm đếm dư; track fragmentation làm một vật thành nhiều ID; occlusion hoặc confidence thấp làm đếm thiếu; quay lại cùng kệ có thể đếm lại vật cũ.

5.4 Khuyến nghị nâng độ tin cậy counting

- Chỉ chấp nhận track tồn tại tối thiểu N frame và có median/max confidence đạt ngưỡng.
- Gộp track fragment bằng appearance embedding, spatial-temporal overlap hoặc re-identification nhẹ.
- Dùng line/zone crossing nếu quy trình quay video có hướng di chuyển chuẩn.
- Frame sampling và scene segmentation để tránh xử lý dư và tái đếm khi camera quay lại.
- Đánh giá counting bằng MAE, RMSE, exact-count accuracy và per-SKU error, không chỉ mAP detection.
- Đưa sample khó/low-confidence sang manual review hoặc multimodal QA thay vì tự động chốt.


5.5 Detection, OCR, Color và SKU Fusion

Phân hệ	Mục tiêu	Trạng thái source	Đầu ra nên có
Detection	Tìm vị trí và class sơ bộ	Có trong runtime	bbox, detector_class, confidence
Tracking	Duy trì ID qua frame	Có trong runtime video	track_id, lifespan, trajectory
Counting	Suy ra số lượng không trùng	PoC bằng unique track ID	quantity + counting confidence

Phân hệ	Mục tiêu	Trạng thái source	Đầu ra nên có
OCR	Đọc brand/SKU text	Chỉ có data triage flag	tokens, normalized text, OCR score
Color	Trích màu bao bì đặc trưng	Chỉ có data triage flag	palette/embedding + quality score
SKU Fusion	Hợp nhất evidence	Chưa có runtime	final_sku, score, reason, uncertainty

6. Pipeline dữ liệu, pre-annotation và training

Pipeline dữ liệu và huấn luyện mô hình



Hình 2. Pipeline dữ liệu và huấn luyện được tổng hợp từ ba script và notebook.

6.1 Gemini image triage

gemini_triage_agent.py duyệt ảnh theo thư mục, sử dụng few-shot pass/fail và structured output để đánh giá ba cờ chất lượng:

- ``is_whole_package_visible``: thấy tối thiểu khoảng 80% ranh giới vật thể, phù hợp annotation YOLO.
- ``is_text_readable``: brand hoặc mã định danh đủ nét cho OCR.
- ``is_color_patch_clear``: mảng màu đặc trưng không bị cháy sáng hoặc chìm tối.

Kết quả được ghi từng dòng vào ``trriage_results.jsonl``, flush ngay để hỗ trợ resume. Script có retry cho lỗi 429/500 và exponential backoff.

Schema inconsistency

Pydantic ``ImageTriage`` chỉ định nghĩa ba boolean, trong khi prompt yêu cầu thêm ba reasoning field. Cần chọn một schema duy nhất; production nên lưu reasoning/quality score trong schema hoặc bỏ yêu cầu reasoning khỏi prompt.

6.2 Auto routing

auto_router(2).py đọc JSONL và copy cùng một ảnh vào một hoặc nhiều thư mục phù hợp: ``usable_for_YOLO``, ``usable_for_OCR``, ``usable_for_Color``; nếu không đạt tiêu chí nào thì đưa vào ``unusable_images``. Tên file được flatten từ relative path để tránh trùng giữa SKU folder.

6.3 Hybrid pre-annotation

pre_annotation.py dùng YOLO-World ``yolov8x-worldv2.pt`` với 60 semantic descriptions tương ứng hai mô tả cho mỗi SKU. Raw class ID được map về 30 SKU bằng phép chia nguyên cho 2. Mười class dễ hallucination được crop và gửi multimodal LLM để xác nhận trước khi lưu label.

Bug định dạng label

File YOLO label phải bắt đầu bằng numeric class ID. Source hiện ghi `final\_label` dạng chuỗi SKU vào file TXT. Cần thay bằng `final\_id` và giữ `classes.txt/data.yaml` làm mapping duy nhất.

Fail-open risk

Khi LLM lỗi, parse lỗi hoặc crop rỗng, source mặc định giữ bounding box. Điều này tối ưu recall nhưng có thể đưa false positive vào dataset. Nên lưu trạng thái `needs\_review` và không tự động coi là nhãn sạch.

6.4 Training YOLOv8n 30 SKU

Thuộc tính	Giá trị trong notebook	Nhận xét
Dataset	Roboflow project version 1, YOLOv8 format	API key phải nằm trong secret store
Base model	yolov8n.pt pretrained	Phù hợp PoC/latency thấp
Classes	30	Khớp danh sách pre-annotation
Train/Valid/Test	374 / 46 / 47 images	Tập valid/test nhỏ; cần kiểm tra leakage theo video/source
Epochs	100	Training hoàn tất khoảng 0,226 giờ trên T4
Image size / Batch	640 / 16	Cấu hình cân bằng tốc độ và độ chính xác
Augmentation	rotation, translate, scale, mosaic, mixup, HSV, horizontal flip	Có chủ đích theo điều kiện kho
Test metrics	P 0,866; R 0,831; mAP50 0,847; mAP50-95 0,745	47 ảnh/54 instances; chỉ là PoC evidence
Artifact	best_YOLOv8_30_SKU_v1.pt	Cần export ONNX và version metadata

Nguồn nội bộ: [AIII]_Train_model.ipynb

6.5 Đánh giá chất lượng model đúng cách

- Báo cáo per-class Precision/Recall/AP thay vì chỉ metric tổng.
- Kiểm tra confusion matrix, đặc biệt các SKU có bao bì/màu/hình dạng gần nhau.
- Tách train/valid/test theo video/session/ngày thu thập để tránh các frame gần giống rơi vào nhiều split.
- Tạo hard-negative set gồm background, vật không thuộc 30 SKU, bao bì rỗng và vật bị che.
- Tạo test thực tế theo điều kiện kho: ánh sáng, blur, góc nghiêng, xếp chồng, khoảng cách và camera khác nhau.
- So sánh `.pt` và `.onnx` sau export để phát hiện accuracy drift.

7. Data contract và schema tích hợp**7.1 R2 object key convention**

Loại	Pattern hiện tại	Khuyến nghị
Video	raw-video/YYYY/MM/<uuid>.mp4	Giữ UUID; lưu MIME, size, checksum và original filename trong job table
Image	raw-image/YYYY/MM/<uuid>.jpg	Không ép .jpg nếu upload PNG/WebP; xác định extension từ validated MIME

Loại	Pattern hiện tại	Khuyến nghị
Report	reports/ Bao_Cao_Kiem_Kho_YYYY_MM_DD.xlsx	Thêm job_id/timestamp để tránh overwrite

7.2 Request tới FastAPI

```
POST /api/v1/process-video
{
  "video_key": "raw-video/2026/07/<uuid>.mp4",
  "teams_message_id": "<teams-message-id>",
  "callback_url": "https://<n8n-host>/webhook/ai-callback-result"
}
```

Tên `video\_key` và endpoint `process-video` đang được giữ để tương thích ngược nhưng thực tế nhận cả ảnh và video. Phiên bản API tiếp theo nên dùng `media\_key` và `/api/v1/media/jobs`, đồng thời hỗ trợ alias trong giai đoạn migration.

7.3 Response tiếp nhận

```
HTTP 202 Accepted
{
  "message": "Đã tiếp nhận file. Hệ thống đang phân loại ảnh/video ngầm."
}
```

Thiếu job identifier

Response chưa trả `job\_id`, `status\_url` hoặc correlation ID. Điều này làm khó retry, trace và kiểm tra trạng thái.

7.4 Success callback

```
{
  "status": "SUCCESS",
  "teams_message_id": "<teams-message-id>",
  "raw_video_key": "raw-video/2026/07/<uuid>.mp4",
  "media_type": "video",
  "detections": {
    "FL_0002_BotCake": {
      "count": 3,
      "avg_confidence": 0.9123,
      "min_confidence": 0.8610,
      "max_confidence": 0.9540
    }
  }
}
```

7.5 Error callback

```
{
  "status": "ERROR",
  "teams_message_id": "<teams-message-id>",
  "error_message": "<sanitized-error-message>"
}
```

- Callback cần `job\_id`, `attempt`, `model\_version`, `processing\_started\_at`, `processing\_completed\_at` và `trace\_id`.
- FastAPI phải gọi `raise\_for\_status()` và retry có backoff; n8n phải trả 2xx acknowledgement.
- Error message gửi ra ngoài phải được sanitize, còn stack trace giữ trong log nội bộ.

7.6 Supabase record được suy ra

Field	Ý nghĩa	Khuyến nghị type/constraint
video_key	R2 key của media	text, indexed

Field	Ý nghĩa	Khuyến nghị type/constraint
raw_image_url	URL xem ảnh hoặc placeholder video	text nullable; tránh public URL dài hạn
object_class	Class detector	text
sku_code	SKU cuối cùng	text; FK tới sku_master
quantity	Số lượng	integer >= 0
confidence_array	Min/max confidence serialized	jsonb thay vì text
final_confidence	Confidence tổng	numeric 0..1
teams_message_id	Trace về Teams	text indexed
scan_time	Thời điểm ghi	timestampz
job_id	Định danh job	uuid unique; hiện chưa có
model_version	Version model	text; hiện chưa có
status	SUCCESS/ERROR/REVIEW	enum/text; hiện chưa có

8. Deployment và vận hành

8.1 Docker Compose hiện tại

docker-compose.yml định nghĩa một service FastAPI, build từ local Dockerfile, restart `unless-stopped`, map port `8000:8000`, load `.env`, mount `./models:/app/models` và `./app:/app/app`.

Port inconsistency

Compose expose port 8000, trong khi comment CLI của main.py dùng Uvicorn port 8080. Cần thống nhất Dockerfile CMD, compose port và Cloudflare Tunnel origin.

8.2 Các thành phần còn thiếu cho production

Khoảng trống	Tác động	Giải pháp
Không có durable queue	Job mất khi process/container restart	Redis/SQS + Celery/RQ/Arq/Dramatiq worker
Không có healthcheck/readiness	Tunnel/LB không biết model sẵn sàng	/health/live và /health/ready
Không có resource limit	Video lớn có thể chiếm CPU/RAM	Docker limits, max video duration/size, concurrency limit
Không có structured metrics	Khó theo dõi latency/error/throughput	JSON logging, Prometheus/OpenTelemetry
Bind mount source code	Không immutable, có thể lệch môi trường	Build image versioned; chỉ mount model/config khi cần
Không thấy GPU config	Có thể inference CPU ngoài dự kiến	CPU benchmark hoặc NVIDIA runtime profile
Không có model registry/version	Không truy vết kết quả theo model	MODEL_VERSION + artifact checksum + registry

8.3 Vận hành job bất đồng bộ

FastAPI BackgroundTasks phù hợp PoC hoặc tắc vự ngăn, nhưng không cung cấp persistence, visibility timeout, retry, DLQ hoặc distributed concurrency. Với video, khuyến nghị API chỉ validate/enqueue và trả job_id; worker riêng tải media, inference, callback và cập nhật trạng thái.

9. Bảo mật và quản trị dữ liệu

9.1 Phát hiện credential exposure

Hành động bắt buộc

Các file được cung cấp từng chứa R2 Access Key/Secret, Gemini API key fallback và Roboflow API key. Không chỉ xóa khỏi code: phải revoke/rotate vì key đã đi vào file, notebook hoặc workflow export. Sau đó kiểm tra Git history, n8n execution data và notebook outputs.

9.2 Kiểm soát đề xuất

Miền	Kiểm soát tối thiểu	Mức ưu tiên
Secrets	n8n Credentials, environment secret store, no fallback key, secret scanning	P0
Webhook auth	HMAC signature hoặc bearer token; allowlist callback host	P0
R2	Private bucket, short TTL presigned PUT/GET, object size/MIME policy	P0
CORS	Không dùng `*`; chỉ allow upload portal origin	P0
Input validation	Extension + MIME + magic bytes + codec + size/duration	P0
Logging	Không log token, signed URL, PII hoặc raw stack trace ra Teams	P1
Database	Row-level access, least privilege service role, audit fields	P1
Retention	Lifecycle rule cho raw media và reports	P1
Supply chain	Pin dependency versions, scan image, SBOM	P2

10. Đánh giá trạng thái hiện tại

Capability	Hiện trạng	Điểm mạnh	Hạn chế	Mức sẵn sàng
Dataset QA	Gemini triage + routing	Có resume/retry/few-shot	Model/schema cần chuẩn hóa	PoC
Annotation	YOLO-World + targeted LLM	Giảm effort ban đầu	Label format bug; fail-open	PoC
Training	YOLOv8n 30 SKU	Có augmentation và test	Dataset test nhỏ; key hardcoded	PoC+
Image inference	ONNX + FastAPI	Đơn giản, latency thấp	Chưa fusion/OCR/Color	PoC+


Capability	Hiện trạng	Điểm mạnh	Hạn chế	Mức sẵn sàng
Video counting	ByteTrack stream	Giảm đếm lặp frame	Track ID không bằng ground truth quantity	PoC
Orchestration	3 workflow rõ vai trò	End-to-end flow	Inactive/test URLs/no durable idempotency	PoC
Reporting	Supabase + XLSX + Teams	Tự động trả kết quả	Filename collision, public URL	PoC
Security/Operations	Một phần	Có env file cho backend	Secret exposure, thiếu queue/metrics	Chưa sẵn sàng

11. Rủi ro, root cause và giải pháp

Mức	Vấn đề	Root cause	Workaround	Giải pháp lâu dài
P0	Credential đã hardcode	Secret đặt trực tiếp trong code/notebook/workflow	Rotate ngay và xóa khỏi bản active	Secret manager, scanning và least privilege
P0	ERROR bị ghi thành NO_OBJECT	Workflow 3 không branch theo status	Thêm IF/Switch trước parser	Job state machine + typed callback schema
P0	Callback dùng test URL	Workflow chưa chuyển production path	Đổi sang `/webhook/` khi active	Config theo environment, automated deployment
P0	Job có thể mất khi restart	FastAPI BackgroundTasks không durable	Giới hạn video và tránh restart khi job chạy	Durable queue + worker + retries/DLQ
P1	Đếm sai do track fragmentation	Unique track ID được xem như item vật lý	Min track length và confidence filtering	ReID/dedup + counting benchmark + capture SOP
P1	Runtime model có thể là COCO/default	Tên file `yolov8n.onnx` không chứng minh fine-tuned	Kiểm tra class names khi startup	Versioned model artifact + checksum + registry
P1	YOLO label TXT sai format	Pre-annotation ghi class name thay numeric ID	Thay `final_label` bằng `final_id`	Dataset validation CI trước train
P1	Report bị overwrite	Tên file chỉ theo ngày	Thêm timestamp/UUID	Artifact table + immutable versioned key
P1	Port/tunnel không nhất quán	Compose 8000, source comment 8080	Sửa một phía cho khớp	Single config source + health check
P2	Dedup Teams không bền	Static data giới hạn 50 ID	Tăng cửa sổ tạm thời	DB idempotency unique constraint
P2	OCR/Color chưa vào runtime	Mới có dataset triage	Manual review các class khó	Feature services + calibrated fusion
P2	LLM fail-open làm bẩn dataset	Lỗi API mặc định giữ nhãn	Đánh dấu review queue	Human-in-the-loop và QA sampling

12. Kiến trúc mục tiêu production

Kiến trúc mục tiêu cho production



Hình 3. Kiến trúc mục tiêu: API chỉ enqueue; worker xử lý durable; fusion và reporting tách rời.

12.1 Luồng đề xuất

25. Teams/n8n tạo `job\_id` và pre-signed upload URL; metadata job được ghi trước khi upload.
26. Upload portal PUT media vào R2 private và gửi completion event kèm checksum.
27. n8n hoặc R2 event gọi API Gateway; API validate object metadata, auth, idempotency rồi enqueue.
28. Inference worker tải media, thực hiện decode/frame sampling và YOLO detection.
29. Video branch chạy tracking/counting; crop có chất lượng đủ được gửi OCR và Color services.
30. SKU Fusion hợp nhất detector, OCR và Color theo deterministic rules hoặc calibrated model; low-confidence chuyển review.
31. Result service ghi transaction vào Supabase, callback n8n với retry và idempotency.
32. Report generator tạo artifact versioned, R2 private phát signed GET URL và Teams nhận thông báo cuối.

12.2 Chiến lược SKU Fusion

- Rule-first cho các SKU có text/logo xác định rõ; OCR exact/fuzzy match có trọng số cao.
- Color chỉ là supporting evidence vì ánh sáng thay đổi; dùng color normalization và quality gating.
- Detector class là prior; fusion không nên thay đổi class khi OCR/Color không đủ chất lượng.
- Calibrate confidence trên validation set; output gồm detector_score, ocr_score, color_score, fusion_score và decision_reason.
- LLM chỉ triage case bất định hoặc QA báo cáo, không trực tiếp thực thi quantity/business rule.

13. Kế hoạch kiểm thử và tiêu chí nghiệm thu

13.1 Unit tests

Đối tượng	Test chính	Expected output
Pydantic schema	Thiếu field, URL sai, extension không hỗ trợ	422 hoặc error có mã rõ
Object key parser	Image/video keys hợp lệ và path traversal	Chỉ chấp nhận prefix/extension allowlist
Aggregation	Confidence list rỗng/1/nhiều phần tử	count và avg/min/max chính xác
Tracking postprocess	Track ngắn, ID fragment, class thay đổi	Rule dedup ổn định
Workflow parser	SUCCESS empty, SUCCESS result, ERROR	Ba nhánh không lẫn nhau

Đối tượng	Test chính	Expected output
Report filename	Nhiều job cùng ngày	Không overwrite

13.2 Integration và end-to-end tests

- Upload ảnh hợp lệ -> R2 -> FastAPI -> callback -> Supabase -> XLSX -> Teams.
- Upload video có nhiều lần xuất hiện cùng SKU -> quantity không đếm theo số frame.
- File hỏng, sai MIME, quá kích thước hoặc object key không tồn tại -> ERROR branch.
- Callback trả 500/timeout -> retry, không mất job, không insert trùng.
- Restart API/worker giữa job -> job được resume hoặc retry từ queue.
- Hai job cùng ngày -> hai report keys khác nhau.
- Message webhook gửi lặp -> chỉ một job được tạo nhờ unique idempotency constraint.

13.3 AI acceptance metrics

Metric	Ý nghĩa	Khuyến nghị PoC/pilot
Per-SKU AP50/AP50-95	Detection accuracy theo class	Không class trọng yếu nào dưới threshold đã thống nhất
Recall SKU trọng yếu	Giảm bỏ sót	Ưu tiên recall cho nguyên liệu quan trọng
Counting MAE	Sai số tuyệt đối quantity	Báo theo SKU và scene
Exact count accuracy	Tỷ lệ video đếm đúng hoàn toàn	Theo SOP quay video
False positive rate	Vật không thuộc SKU bị nhận nhầm	Hard-negative set
P95 processing latency	Thời gian xử lý media	Tách upload, queue wait, inference, report
Job success rate	Độ tin cậy end-to-end	Bao gồm callback và report delivery

14. Roadmap cải tiến

Giai đoạn	Mục tiêu	Deliverables	Exit criteria
P0 - Security & Correctness	Loại lỗi có thể gây mất dữ liệu/rò secret	Rotate keys; fix ERROR branch; production webhook; model verification; fix label format	Không còn secret trong source; E2E happy/error path pass
P1 - Reliable Runtime	Job bền vững và truy vết được	job_id, queue worker, retries/DLQ, healthcheck, structured logs	Restart không làm mất job; callback idempotent
P2 - Counting Quality	Giảm ID fragmentation và đếm sai	track quality filters, SOP quay video, counting benchmark	MAE/exact accuracy đạt pilot target
P3 - SKU Fusion	Giảm nhầm SKU tương tự	OCR service, Color feature, fusion rules/model, review queue	Per-SKU confusion giảm trên hard set
P4 - MLOps	Model versioning và continuous improvement	dataset registry, experiment tracking, ONNX parity, drift monitoring	Mọi result truy ra model/data version
P5 - Scale & Governance	Vận hành nhiều kho/user	multi-tenant config, quotas, retention, RBAC, dashboard	SLA, cost và audit đạt yêu cầu

Phụ lục A. Danh mục 30 SKU trong pipeline

Class ID	SKU code	Nguồn mapping
0	YE_0003_MenTrang	ROBOFLOW_CLASS_NAMES / dataset data.yaml
1	ISO_SN_0010_BanhCracker	ROBOFLOW_CLASS_NAMES / dataset data.yaml
2	ISO_PA_0029_CuonDayThungNho	ROBOFLOW_CLASS_NAMES / dataset data.yaml
3	ISO_PA_0020_BaoBanhCuonMem	ROBOFLOW_CLASS_NAMES / dataset data.yaml
4	OF_0013_GangTay	ROBOFLOW_CLASS_NAMES / dataset data.yaml
5	PA_0014_NapBanhKemTron	ROBOFLOW_CLASS_NAMES / dataset data.yaml
6	OF_0011_GiayNen	ROBOFLOW_CLASS_NAMES / dataset data.yaml
7	ISO_OF_0012_BaoRac	ROBOFLOW_CLASS_NAMES / dataset data.yaml
8	OF_0009_GiayVS	ROBOFLOW_CLASS_NAMES / dataset data.yaml
9	OF_0010_GiayBep	ROBOFLOW_CLASS_NAMES / dataset data.yaml
10	OF_0008_NuocLavie	ROBOFLOW_CLASS_NAMES / dataset data.yaml
11	OF_0004_NuocRuaTay	ROBOFLOW_CLASS_NAMES / dataset data.yaml
12	OF_0003_NuocRuaChen	ROBOFLOW_CLASS_NAMES / dataset data.yaml
13	OF_0004_MangBocThucPham	ROBOFLOW_CLASS_NAMES / dataset data.yaml
14	FL_0011_BotCustard	ROBOFLOW_CLASS_NAMES / dataset data.yaml
15	OF_0001_VimVeSinh	ROBOFLOW_CLASS_NAMES / dataset data.yaml
16	FV_0003_Chuai_Trai	ROBOFLOW_CLASS_NAMES / dataset data.yaml
17	CH_0006_SocolaCompoundTrang	ROBOFLOW_CLASS_NAMES / dataset data.yaml
18	FL_0002_BotCake	ROBOFLOW_CLASS_NAMES / dataset data.yaml
19	SN_0019_Oreo	ROBOFLOW_CLASS_NAMES / dataset data.yaml

Class ID	SKU code	Nguồn mapping
20	PW_0015_BotNoi	ROBOFLOW_CLASS_NAMES / dataset data.yaml
21	JM_0007_MutPhuBanh	ROBOFLOW_CLASS_NAMES / dataset data.yaml
22	FV_0002_CaRot_Cu	ROBOFLOW_CLASS_NAMES / dataset data.yaml
23	FV_0002_CaRot_Bich	ROBOFLOW_CLASS_NAMES / dataset data.yaml
24	BK_0007_BoLatPilot	ROBOFLOW_CLASS_NAMES / dataset data.yaml
25	FL_0004_BotAtta	ROBOFLOW_CLASS_NAMES / dataset data.yaml
26	FL_0013_BotXanhLa	ROBOFLOW_CLASS_NAMES / dataset data.yaml
27	FL_0014_BotCam	ROBOFLOW_CLASS_NAMES / dataset data.yaml
28	PW_0010_CafeBot_Bich	ROBOFLOW_CLASS_NAMES / dataset data.yaml
29	PW_0010_CafeBot_Hu	ROBOFLOW_CLASS_NAMES / dataset data.yaml

Phụ lục B. Environment variables đề xuất

Variable	Mục đích	Ghi chú
CLOUDFLARE_ACCOUNT_ID	R2 endpoint	Secret/config store
R2_ACCESS_KEY_ID	R2 auth	Rotate; least privilege
R2_SECRET_ACCESS_KEY	R2 auth	Rotate; never log
R2_BUCKET_NAME	Bucket raw/report	Config
MODEL_PATH	Đường dẫn ONNX	Không hardcode model name
MODEL_VERSION	Version model	Ghi vào mọi result
INFERENCE_CONF_THRESHOLD	Detection threshold	Calibrate per model/SKU
MAX_MEDIA_BYTES	Giới hạn upload	Validate cả portal/API
MAX_VIDEO_SECONDS	Giới hạn duration	Chống resource exhaustion
AI_ENGINE_AUTH_TOKEN	n8n -> API auth	Secret
CALLBACK_ALLOWED_HOSTS	Allowlist callback URL	Chống SSRF
CALLBACK_TIMEOUT_SECONDS	HTTP timeout	Config
CALLBACK_MAX_RETRIES	Retry policy	Config
QUEUE_URL	Durable queue	Secret/config

Variable	Mục đích	Ghi chú
DATABASE_URL / SUPABASE_*	Persistence	Secret
LOG_LEVEL	Logging	Không chứa secret
GEMINI_API_KEY	Dataset QA only	Không fallback hardcoded
ROBOFLOW_API_KEY	Dataset download only	Notebook secret

Phụ lục C. Danh mục nguồn phân tích

Nguồn	Nội dung sử dụng	Lưu ý
pre_annotation.py	YOLO-World, semantic descriptions, targeted LLM QA, 30 SKU mapping	Có credential fallback và label format issue
gemini_triage_agent.py	Few-shot data quality triage, JSONL resume/retry	Schema/prompt mismatch cần chuẩn hóa
auto_router(2).py	Routing ảnh cho YOLO/OCR/Color/Unusable	Đường dẫn Windows hardcoded
main(1).py	FastAPI, R2 download, image/video routing, callback	BackgroundTasks và callback reliability
yolo_service.py	ONNX inference, ByteTrack, aggregation	Unique tracks không đồng nghĩa vật lý tuyệt đối
docker-compose.yml	Container, port, env, volumes	Không có Dockerfile trong bộ tài liệu
Workflow 1 JSON	Teams command, UUID, pre-signed URL, upload card	Secret hardcoded; active false
Workflow 2 JSON	Teams progress, FastAPI trigger	Quick Tunnel, webhook-test, active false
Workflow 3 JSON	Callback parse, Supabase, Excel, R2, Teams	ERROR masking và filename collision
[AIII]_Train_model.ipynb	Roboflow download, YOLOv8n training/testing, metrics	API key exposed; small test set

Kết luận

Hệ thống có nền tảng PoC tốt và luồng end-to-end rõ ràng. Ưu tiên trước pilot là xử lý credential, sửa contract/error handling, xác minh đúng model ONNX, chuyển sang durable job execution và xây benchmark counting. Sau đó mới tích hợp OCR/Color/SKU Fusion để nâng accuracy cho các SKU tương tự.